

TP5 – Compromis Biais/Variance et autre

I. Chargement et visualisation des données

Chargez les données (TP5.npz) et visualisez-les avec la commande :

```
data = np.load("TP5.npz")
X_train, y_train, X_test, y_test = (data[key] for key in ["X_train", "y_train", "X_test", "y_test"])
plt.scatter(X_train[:, 0], X_train[:, 1], c=y_train, s=1, cmap='rainbow');
plt.show()
plt.scatter(X_test[:, 0], X_test[:, 1], c=y_test, s=1, cmap='rainbow');
plt.show()
```

Questions

Combien y a-t-il de points dans la base d'apprentissage ? Dans la base de test ? Quelle est la dimension des données ?

Combien y a-t-il de classes ? Est-ce que les classes sont bien équilibrées dans la base d'apprentissage et la base de test ?

II. Calcul du biais et de la variance du classifieur 1PPV

On souhaite calculer le biais et la variance du classifieur 1PPV. Pour cela, réalisez $N_{run}=30$ apprentissages en tirant aléatoirement 60% de la base d'apprentissage (random_state sera initialisé avec la somme des 3 derniers numéros de votre carte d'étudiant+le numéro du run) . Vous prédiriez à chaque fois la classe des exemples de la base de test. A partir des N_{run} prédictions, calculez le biais et la variance du classifieur. On pourra pour cela utiliser la fonction mode() de scipy.stats.

Pour un exemple de test,

- le biais vaut 0 si la classe avec le plus de prédictions est la classe correcte, 1 sinon.
- la variance vaut $1 - \text{probabilité de la classe avec le plus de prédictions}$.

Le biais et la variance sont ensuite obtenus en moyennant sur tous les exemples de test. Par exemple, considérons un exemple de test appartenant à la classe 1. Parmi les 30 runs, cet exemple est classé 28 fois 1 et deux fois autre chose. Pour cet exemple, le biais est 0 (car la classe avec le plus de prédictions est la classe correcte) et la variance est $1-28/30$.

III. Etude du compromis biais/variance du classifieur k-PPV

Tracez l'évolution du biais et de la variance en fonction du k des k-ppv. Déterminez la valeur de k qui amène au meilleur compromis Biais, Variance.

Questions

Comment évoluent le biais et la variance avec k ? Retrouve-t-on la théorie ? Comment trouver la valeur de k qui optimise le compromis Biais, variance ?

IV. Reprendre la même étude en utilisant un arbre de décision

Pour les arbres de décision, l'étude sera réalisée en fonction de la profondeur maximale.

Questions

Comment évoluent le biais et la variance avec k ? Retrouve-t-on la théorie ? Comment trouver la valeur de k qui optimise le compromis Biais/variance ?

V. Reprendre la même étude avec les random forest

Pour les forêts d'arbres aléatoires, l'étude sera réalisée en fonction du nombre d'arbres de la forêt.

Questions

Comment évoluent le biais et la variance avec N_b ? Retrouve-t-on la théorie ? Trouver la valeur de N_b qui optimise le compromis Biais/variance ?

VI. Test sur un nouveau jeu de données

On s'intéresse maintenant aux données « TP5a.npz ». Utilisez les hyperparamètres optimaux trouvés à la question précédente et réalisez la classification des données de test avec les random forest.

Affichez le rapport de classification et commentez le résultat en fonction des classes. Conclusion ? D'où vient le problème ? Observer bien les bases d'apprentissage et de test.

Proposez deux solutions afin de remédier au problème. Conclusion sur celle qui amène aux résultats les plus performants.